

Autonomiczny Pojazd

Wykonawcy:
Konstanty Odważny,
Jędrzej Szczerbak,
Paweł Chumski

Promotor:
dr hab. inż. Tomasz Pajchrowski



Współpraca z kołem naukowym RAI





Plan prezentacji


1. Koncepcja projektu
2. Szczegóły techniczne platformy pojazdu
3. Zastosowane technologie
4. Śledzenie linii
5. Własny kontroler
6. Rozpoznawanie obrazu
7. Interfejs użytkownika

Koncepcja projektu

- Stworzenie pojazdu poruszającego się po przygotowanej planszy, który będzie potrafił rozpoznać znaki i odpowiednio się do nich zastosować
- Możliwość sterowania zdalnego za pomocą pada
- Umiejętność zapamiętania stworzonej trasy poprzez jazdę po niej za pomocą kontrolera



Nvidia Jetracer




Jetson Nano i CSI camera

Jetson Nano Developer Kit Specification

GPU	128-core NVIDIA Maxwell™ architecture GPU
CPU	Quad-core ARM® Cortex®-A57 MPCore processor
Memory	4GB 64-bit LPDDR4
Storage	microSD (Card not included)
Video Encode	1x 4K30 2x 1080p60 4x 1080p30 9x 720p30 (H.264/H.265)



Top View



Zastosowane technologie



Flask




PyTorch

YOLOv5





KiCad

OpenCV

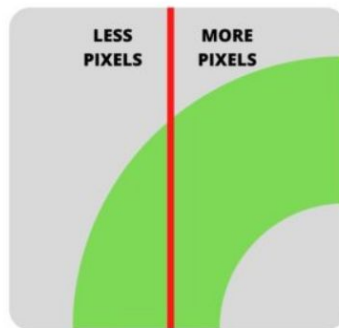

- Biblioteka typu open-source służąca do przetwarzania obrazów oraz machine learning'u
- Zintegrowana i kompatybilna z wieloma innymi bibliotekami np. numpy
- Można używać jej w wielu językach programowania




Śledzenie linii




WHITE = 255
BLACK = 0



RIGHT CURVE



STRAIGHT



LEFT CURVE

YOLO - You Only Look Once


1. Lokalizacja obiektu
2. Klasyfikacja obiektu
3. Rozpoznanie obiektu



“Stop”



“Stop”



Yolo v5

$$\text{Precision} = \frac{TP}{TP + FP}$$


$$\text{Recall} = \frac{TP}{TP + FN}$$

TP = True positive

TN = True negative




FP = False positive

FN = False negative



Wybór zbioru danych

- Wybór danych z platformy Kaggle lub Roboflow
- Zwrócenie uwagi na ilość klas oraz zbalansowanie danych



Przygotowanie zbioru uczącego

- Podział na obrazy oraz pliki opisujące (labels) w formacie .txt, gdzie każdy plik jest zapisany w postaci wzorca:

[Class Number] [center in x] [center in y] [Width] [Height]

2 0.7378676470588236 0.5125 0.030147058823529412 0.055

- Podział zbioru na zbiór treningowy oraz walidacyjny, w proporcji 90% - treningowy, 10% - walidacyjny
- Utworzenie pliku konfiguracyjnego .yaml
- Wybór wcześniej wytrenowanego modelu YOLOv5: yolov5x, yolov5l, yolov5m, yolov5s, yolov5n



Nano
YOLOv5n

4 MB_{FP16}
6.3 ms_{V100}
28.4 mAP_{COCO}



Small
YOLOv5s

14 MB_{FP16}
6.4 ms_{V100}
37.2 mAP_{COCO}



Medium
YOLOv5m

41 MB_{FP16}
8.2 ms_{V100}
45.2 mAP_{COCO}



Large
YOLOv5l

89 MB_{FP16}
10.1 ms_{V100}
48.8 mAP_{COCO}



XLarge
YOLOv5x

166 MB_{FP16}
12.1 ms_{V100}
50.7 mAP_{COCO}

```
1 train: ../data/images/training/  
2 val: ../data/images/validation/  
3  
4 # number of classes  
5 nc: 4  
6  
7 # class names  
8 names: [['speedlimit', 'stop', 'crosswalk', 'trafficlight']]
```


Trenowanie modelu

- Wybór wielkości obrazów wejściowych (standardowo 640x640 px)
- Wybór precyzji: FP32, FP16 lub INT8
- Wybór ilości epok szkolenia (ang. epochs) oraz ilości obrazów pobieranych za jednym razem do trenowania (ang. batch size)
- Walidacja - testowanie w trakcie trenowania
- Trenowanie z użyciem GPU
- Ocena jakości modelu, wskaźniki jakości, wykresy

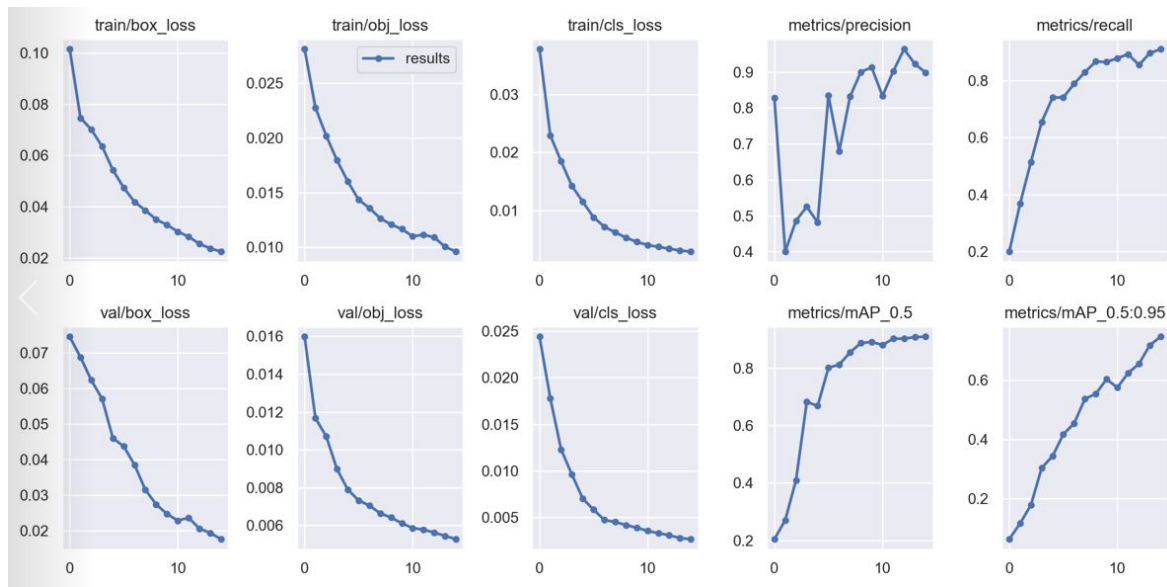
```
AutoAnchor: 5.63 anchors/target, 1.000 Best Possible Recall (BPR). Current anchors are a good fit to dataset
Plotting labels to ../../yolov5-master/runs/train/exp/labels.jpg...
Image sizes 640 train, 640 val
Using 8 dataloader workers
Logging results to ../../yolov5-master/runs/train/exp
Starting training for 15 epochs...
```

Epoch	GPU_mem	box_loss	obj_loss	cls_loss	Instances	Size			
0/14	1.89G	0.1015	0.02809	0.03777	17	640: 100%	<div></div>	50/50	00:24
	Class	Images	Instances	P	R	mAP50	mAP50-95: 100%	<div></div>	3/3 00:01
	all	88	114	0.828	0.199	0.204	0.0629		
Epoch	GPU_mem	box_loss	obj_loss	cls_loss	Instances	Size			
1/14	2.29G	0.07461	0.02276	0.0229	16	640: 100%	<div></div>	50/50	00:19
	Class	Images	Instances	P	R	mAP50	mAP50-95: 100%	<div></div>	3/3 00:01

Wybór modelu

Kryteria:

- Dopasowanie modelu
 - Nadmierne dopasowanie
 - Niedopasowanie
- Ilość klatek na sekundę osiągnięta na platformie (ang. FPS)
- Funkcje strat (ang. loss)
- Funkcje metryki - mAP (mean average precision)



Testowanie modelu

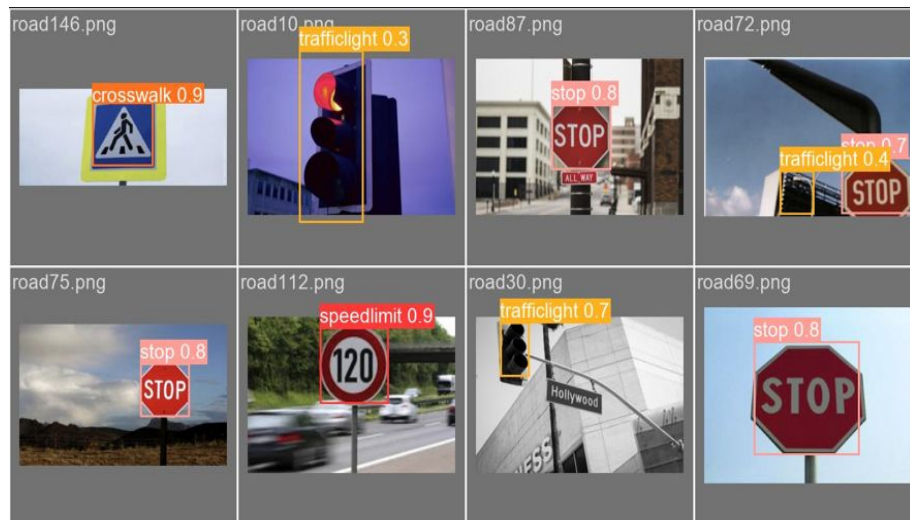
Kroki rozpoznawania obrazu:

- Przygotowanie obrazu (image preprocess) - zmiana wielkości, normalizacja
- Załadowanie modelu sieci neuronowej
- Predykcja - Próg ufności, NMS - non-maximum suppression
- Zaznaczenie rozpoznanego obiektu na obrazie za pomocą ramki ograniczającej (ang. bounding box)




Testowanie modelu

- Testowanie na obrazach:



Estymacja odległości od obiektu

1. Odczytanie wartości ogniskowej obiektywu kamery (ang. focal length).
2. Obliczanie odległości na podstawie ramek znalezionych w fazie rozpoznawania obiektów.



Testowanie modelu

Live Streaming



Interfejs użytkownika

Strona klienta REST, stworzona za pomocą biblioteki Flask

Zalety:

- Łatwość integracji z resztą zadań
- Całość projektu w języku Python
- Możliwość obserwacji obrazu z kamery na żywo



Flask

Live Streaming



Własny kontroler

Założenia wstępne:

- komunikacja BT oraz Wifi
- podstawowe sterowanie pojazdem
- przełączanie trybu ręcznego oraz automatycznego
- odbieranie obrazu z kamery
- zasilanie z opcją ładowania
- możliwość programowania w języku C++
- elastyczność pod przyszłe funkcjonalności




Mikrokontroler

Wybrany model: ESP32-WROOM-32D

- procesor dual-core Xtensa 32-bit LX6 - 240MHz
- 448kB pamięci ROM oraz 520kB pamięci SRAM oraz 4MB pamięci flash
- obsługa magistral cyfrowych, m.in.: I2C, **SPI**, I2S, PWM, UART, IR, CAN
- Standard BT: Bluetooth v4.2 BR/EDR oraz BLE
- Protokoły Wi-Fi: 802.11 b/g/n/d/e/i/k/r
- przetwornik ADC oraz DAC

ESP32 devkitc v4:

- konwerter USB/UART(Silabs CP2102)
- stabilizator AMS1117
- Wyprowadzenia GPIO o rozstawie 2,54 mm



Komunikacja

Radiowa w standardzie Bluetooth:

- standard BL 4.2 oraz BLE
- przepustowość do:
1500Kbps(BT classic)
700Kbps(BLE)
- połączenie master-slave/server-client
- zasięg <100m

Połączenie LAN przez wifi:

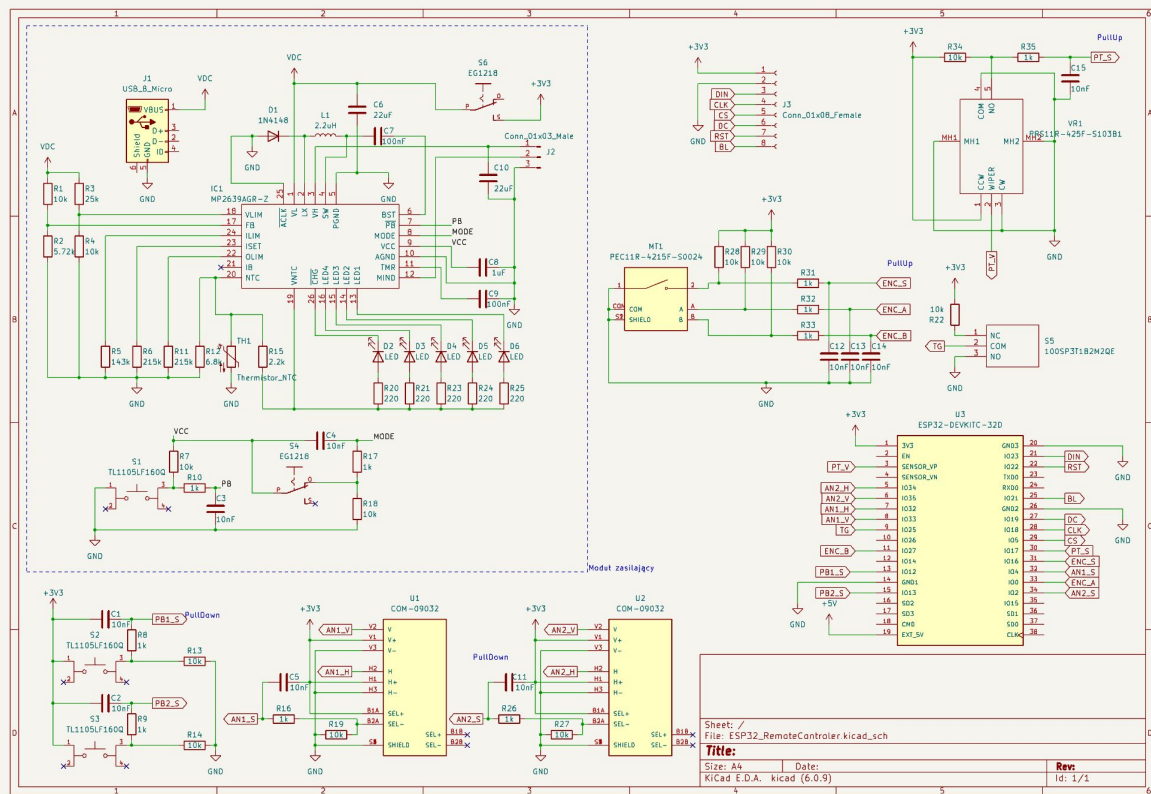
- częstotliwość 2.4GHz
- standardy 802.11 b/g/n
- przepustowość do 150Mbps

Możliwość jednoczesnej pracy obydwu standardów komunikacji przy odpowiednich ustawieniach.

Schemat ideowy

Podstawowe elementy:

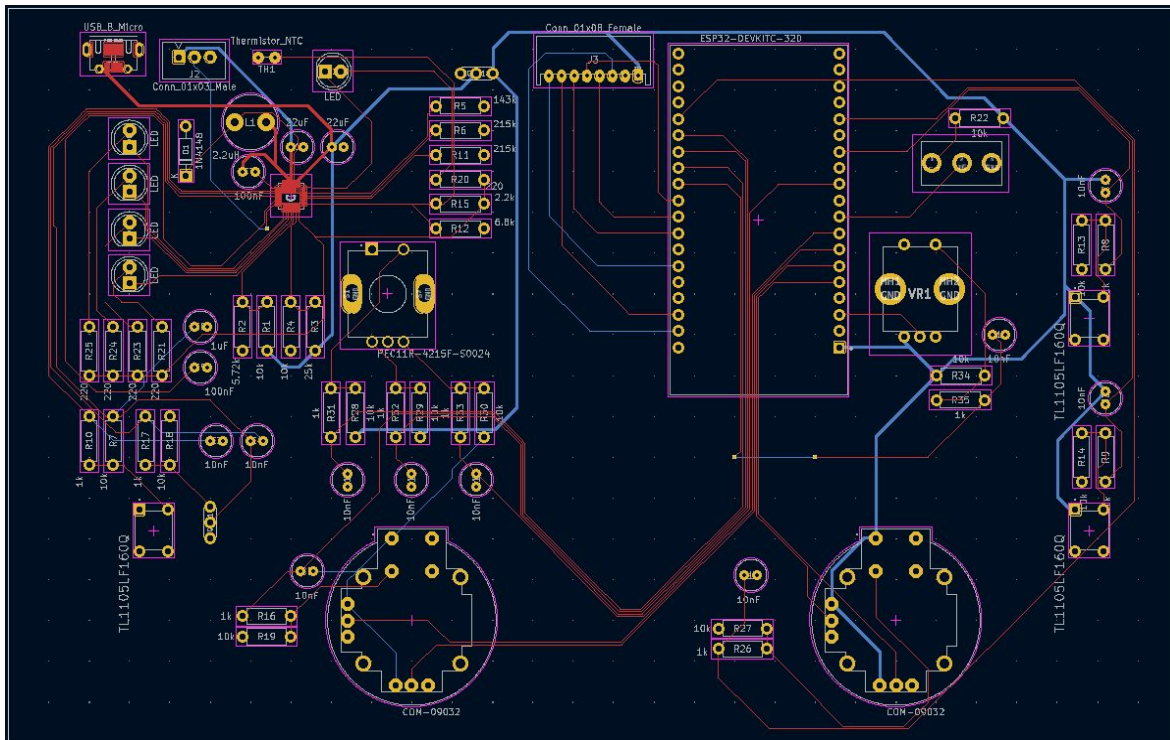
- wyświetlacz LCD TFT(SPI)
- joystick
- enkoder inkrementalny
- potencjometr
- przełącznik
- przyciski
- układ zasilający MP2639AGR -Z
- port micro USB B



Wstępny projekt PCB

Wersja prototypowa zawiera głównie elementy THT. Ułożenie komponentów pasywnych oraz ich wartości wybrano uwzględniając zalecenia producenta.

Wybrano kompromis między ergonomią urządzenia oraz ograniczeniem miejsca i możliwości lutowniczych.



Program

- Język: C++
- Wykorzystane środowisko: arduino IDE
- Biblioteki: "BluetoothSerial.h"/"WiFi.h"
- Rola master/client w zależności od wybranej komunikacji
- Funkcjonalność:
- Odczyt wartości z urządzeń wejściowych
- Wysyłanie ramki danych do pojazdu
- Żądanie obrazu z kamery, wyświetlanie oraz zapis do pamięci flash

Dziękujemy za uwagę